의사결정 트리

(decision tree)

2조 팀원 소개

김규진

김민주

장은조

목차

1

의사결정나무

2

기출문제로

개념잡기!

3

R코드

해석 및 실습

의사결정나무란?

- 의사결정규칙을 도표화하여 관심대상이 되는 집단을 몇 개의 소집단으로 분류(classification)하거나 예측(prediction)을 수행하는 분석방법
- 의사결정나무는 분류 또는 예측을 목적으로 하는 어떤 경우에도 사용될 수 있으나 분석의 정확도보다는 분석과정의 설명이 필요한 경우에 더 유용하게 사용된다.

의사결정나무 형성 → 가지치기 → 타당성 평가 → 해석 및 예측

Day	Outlook	Temperature	Humidity	Wind	PlayTennis
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

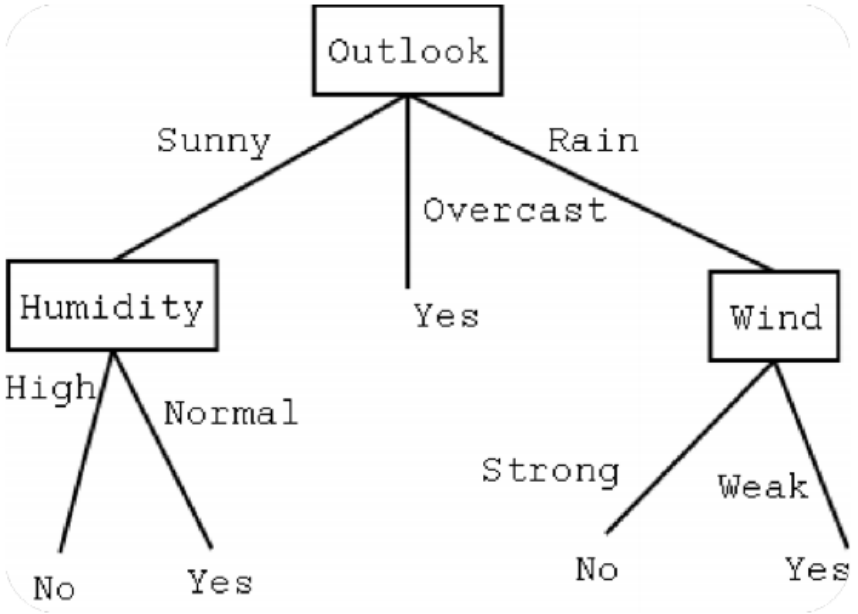

의사결정나무 용어

Node 분류의 기준이 되는 변수가 위치하는 곳

- Parent node 상대적인 개념. 상위 노드
- Child node 하위 노드
- Root node 상위노드가 없는 가장 위의 노드
- Leaf node 하위노드가 없는 가장 아래의 노드
- Internal node Leaf node가 아닌 노드
- Branch 샘플을 분류하는 조건이 위치하는 곳
- Depth Root node에서 특정 노드까지 도달하기 위해 거쳐야 하는 branch의 수

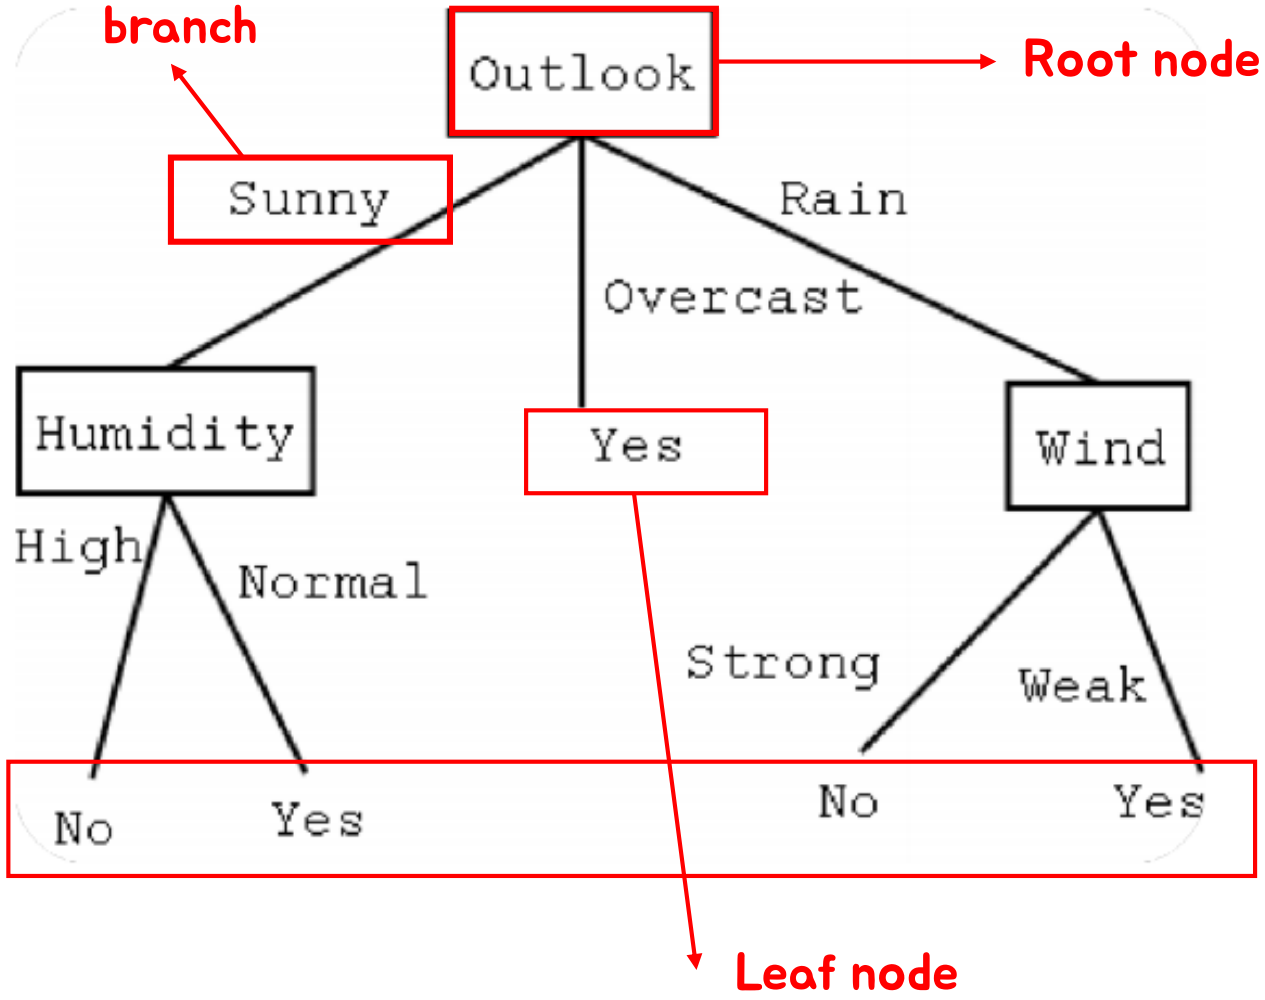
branch
Outlook
Root node
Sunny
Rain
Overcast
Humidity
Yes
Wind
High
Normal
Strong
Weak
No
Yes
No
Yes
Leaf node

의사결정나무 종류

의사결정나무

- 분류나무 (classification tree)
  - : 이산형(범주형) 목표변수의 예측
  - : 목표변수의 각 범주에 속하는 빈도에 기초하여 분할
- 회귀나무 (regression tree)
  - : 연속형(구간형) 목표변수의 예측
  - : 목표변수의 분산과 표준편차에 기초하여 분할

의사결정나무 종류

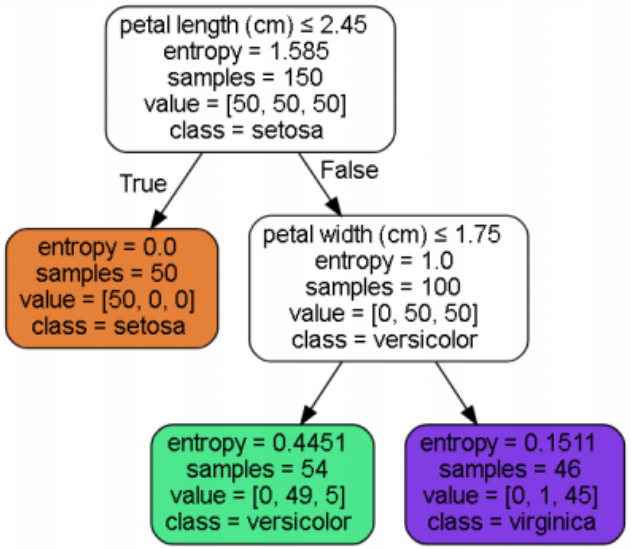

분류나무
(classification tree)

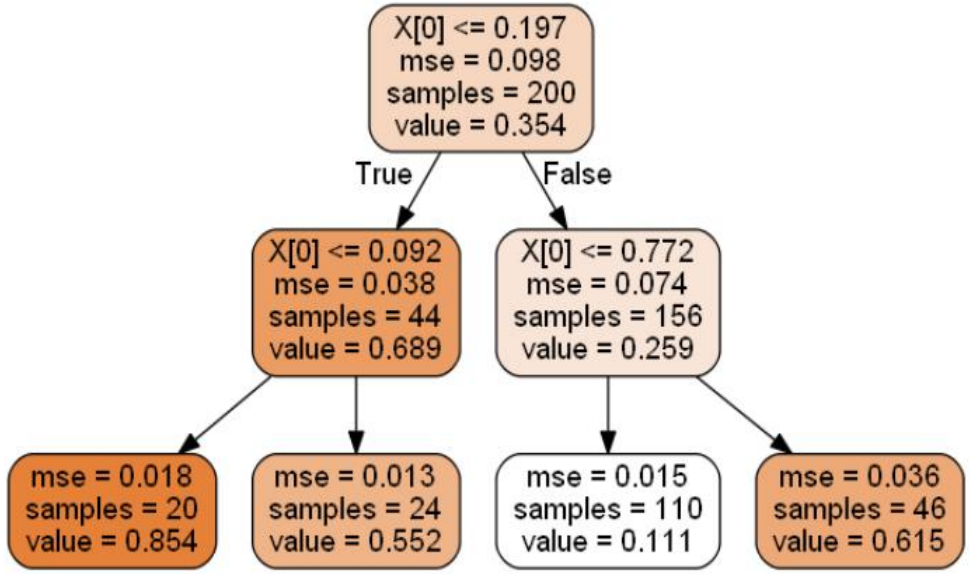

회귀나무
(regression tree)

의사결정나무 장단점

장점	단점
해석의 용이성 - 나무구조로 표현되어 모형을 사용자가 쉽게 이해할 수 있다	비연속성 - 연속형 변수를 비연속적 값으로 취급하기 때문에 분리의 경계점 부근에서 예측오류가 클 가능성이 있다
교호작용효과의 해석 - 두 개 이상의 변수가 결합하여 목표변수에 어떻게 영향을 주는지 쉽게 알 수 있다	비안정성 - 분석용자료(training data)에만 의존하므로 새로운 자료의 예측에서는 불안정할 가능성이 높다.
비모수적 모형 - 선형성, 정규성, 등분산성 등의 가정이 필요하지 않다.	

의사결정나무 방법

모델학습방법

재귀 분할
(recursive partitioning)

가지치기
(pruning)

: 트리구조를 만들기 위해 사용하는 휴리스틱
: 데이터를 부분집합으로 나누고 그 다음 더 작은 부분집합으로
반복해서 나누며, 부분집합의 데이터가 **종료기준**에 도달할 때까지 분할정복
: 분할을 하기 위해 변수를 선택
: 각 분기별로 분할할 때 결정 노드를 생성하며 최고의 후보 변수 선택

종료기준
: 노드에 있는 거의 모든 예시가 같은 클래스를 가질 때
: 예시를 구별하는 변수가 남아있지 않을 때
: 미리 정의된 크기 한도까지 트리가 도달했을 때

어떤 기준 후보에 대해 분할할 것인가?

변수에 대한 여러 개의 기준 후보 중에서 어떤 기준으로 분할 했을 때,
순도(purity) 가 증가하고 불순도(impurity)가 감소하는 방향으로 재귀분할 진행

- 순도(purity) : 부분집합이 단일클래스를 포함하는 정도
- 순수(impurity) : 단일클래스로 이루어진 부분집합

순도 측정법에는 어떤것들이 있나요?

- 엔트로피 (Entropy) , 정보획득량
- 지니 지수 (Gini index)

정보획득량

: 어떤 사건이 얼마만큼의 정보를 줄 수 있는지를 수치화한 값
: 정보획득량 계산하려면 정보함수 와 엔트로피 개념을 알아야 한다!

정보함수

: 정보의 가치를 반환하는데 발생할 확률이 작은 사건일수록 정보의 가치가 크고 반대로 확률이 큰 사건일수록 정보의 가치가 적다

$$I(x) = log_2 \frac{1}{p(x)}$$

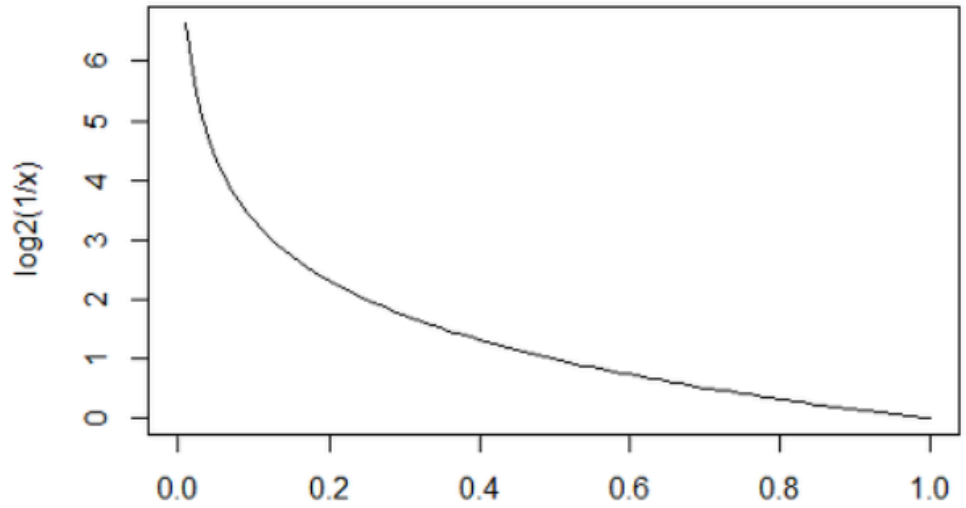

엔트로피 (Entropy)

: 불순도를 측정하는 방법 중 하나
: 엔트로피가 높으면 불순도가 높다는 것을 의미

쉽게 말해,
왼쪽식은 분할 전, 오른쪽식은 분할 후 엔트로피 식

$$Entropy(X) = -\sum_{j=1}^{n} P_j log_2(P_j)$$

: 이때, P_j는 X영역에 속하는 데이터 가운데 j범주에 속하는 데이터 비율

$$Entropy(X) = \sum_{i=1}^{d} R_i \left(-\sum_{j=1}^{n} P_j log_2(P_j)\right)$$

: 이때, R_i는 분할 전 데이터 가운데 분할 후 i범주에 속하는 데이터 비율

엔트로피가 낮게 만드는 것이 목적 !!!

엔트로피 (Entropy)

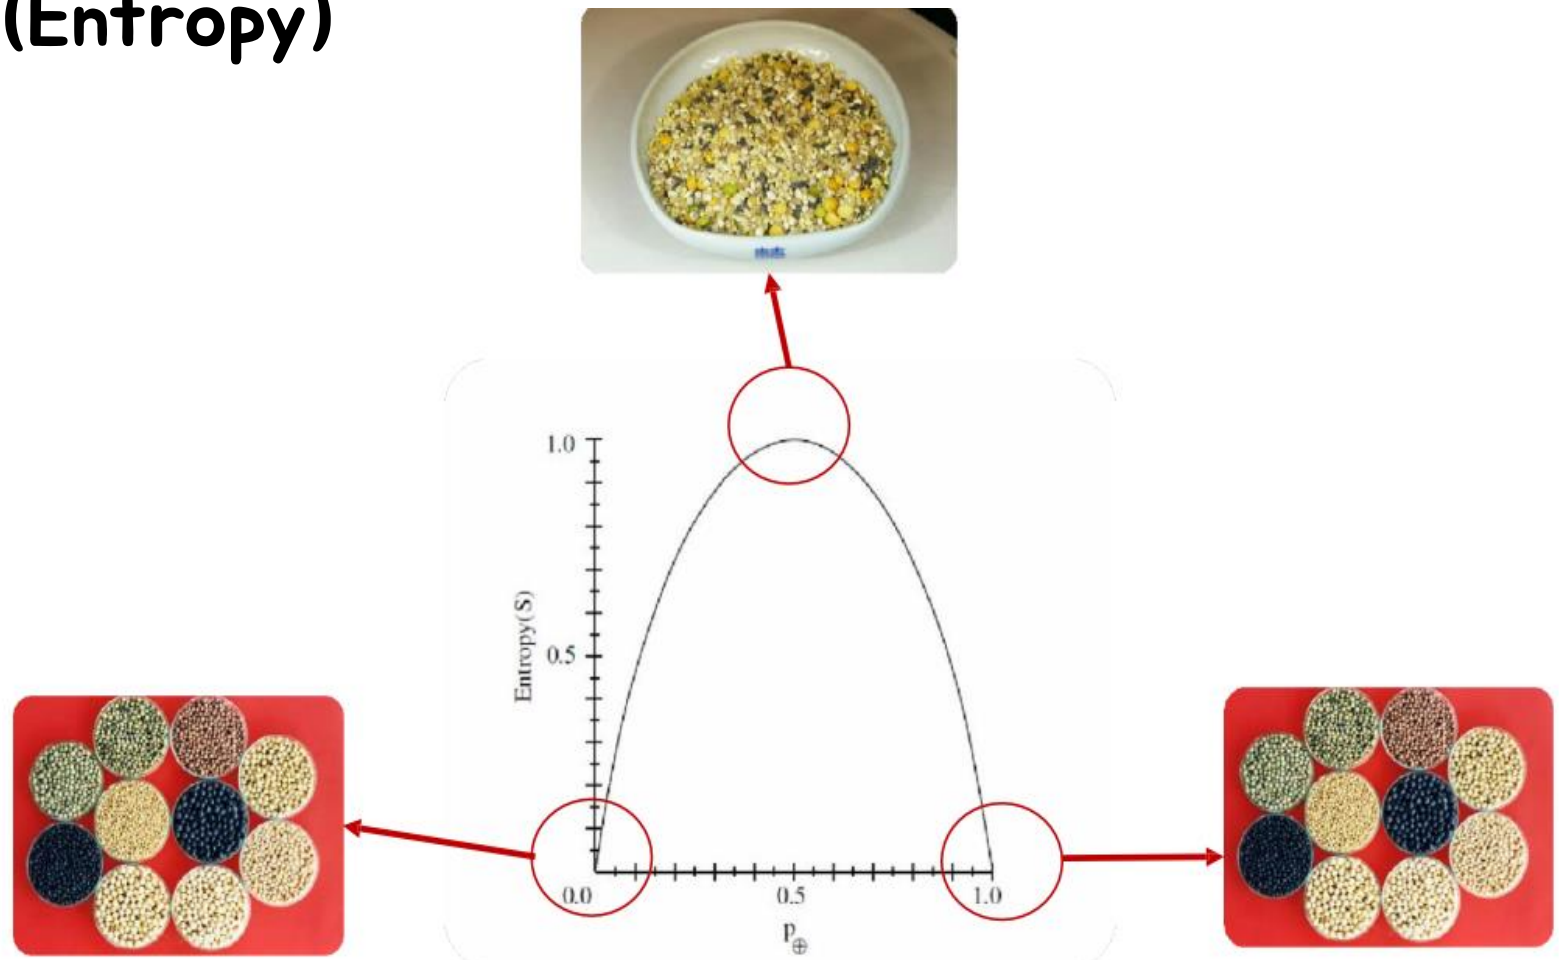

엔트로피 (Entropy)

Day	Outlook	Temperature	Humidity	Wind	PlayTennis
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

D1	D2	D3	D4	D5	D6	D7	D8	D9	D10	D11	D12	D13	D14
NO	NO	YES	YES	YES	NO	YES	NO	YES	YES	YES	YES	YES	NO

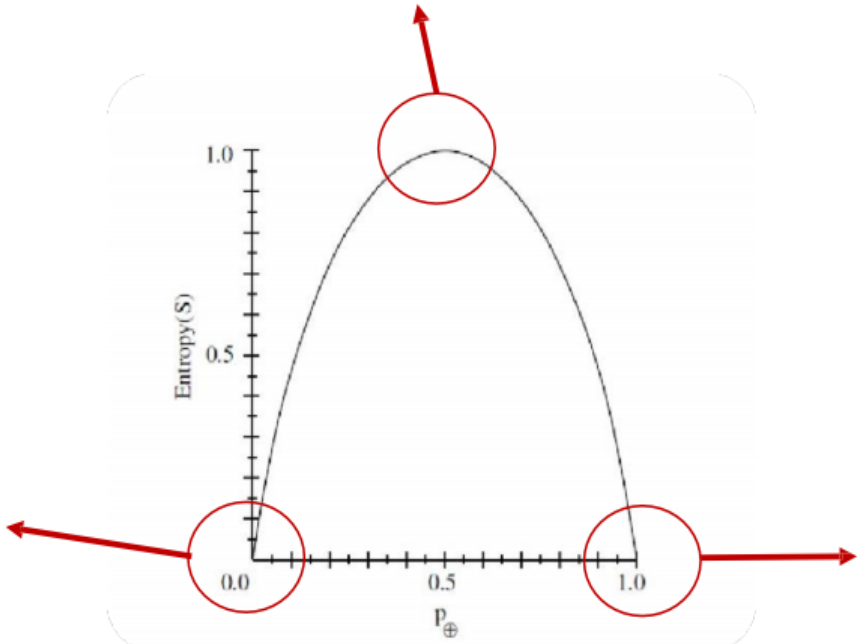

D1	D2	D8
NO	NO	NO

D6	D14
NO	NO

D9	D11
YES	YES

D4	D5	D10
YES	YES	YES

엔트로피 (Entropy)

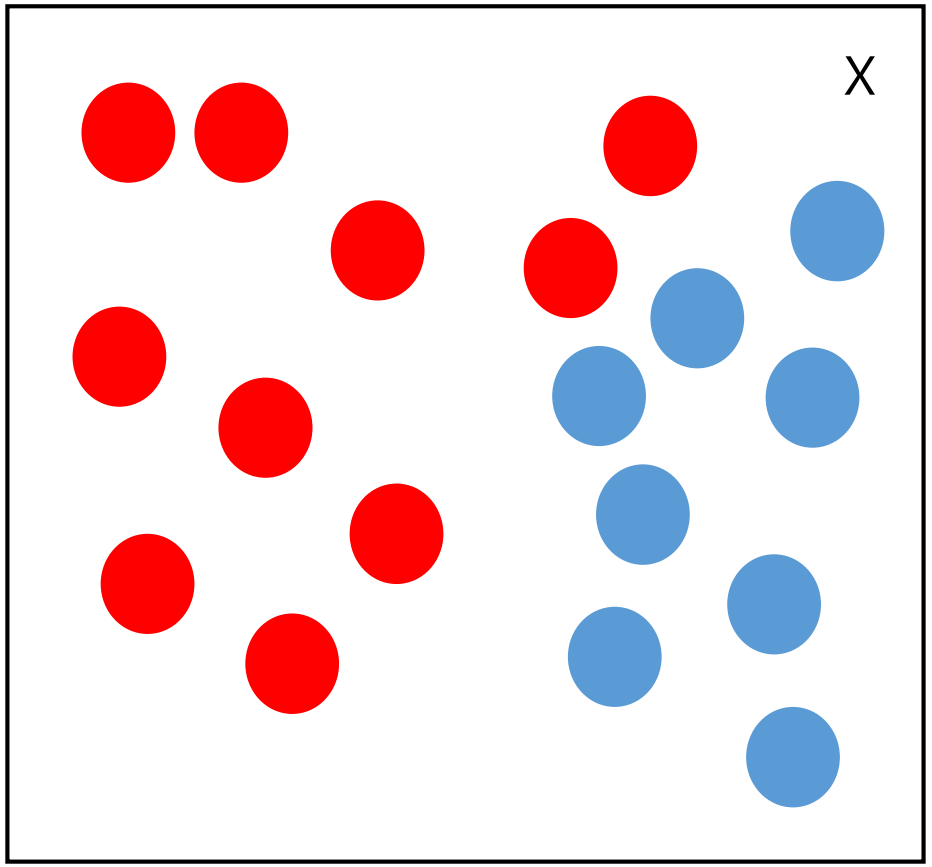

$$Entropy(X) = -\sum_{j=1}^{n} P_j log_2(P_j)$$

; 이때, P_j는 X영역에 속하는 데이터 가운데 j범주에 속하는 데이터 비율

$$= -\frac{10}{18} log_2(\frac{10}{18}) - \frac{8}{18} log_2(\frac{8}{18}) \quad = 0.991$$

P_1 : X영역에 속하는 전체 데이터 18개 가운데 첫번째 범주(빨간공)에 속하는 데이터의 비율

P_2 : X영역에 속하는 전체 데이터 18개 가운데 두번째 범주(파란공)에 속하는 데이터의 비율

엔트로피 (Entropy)

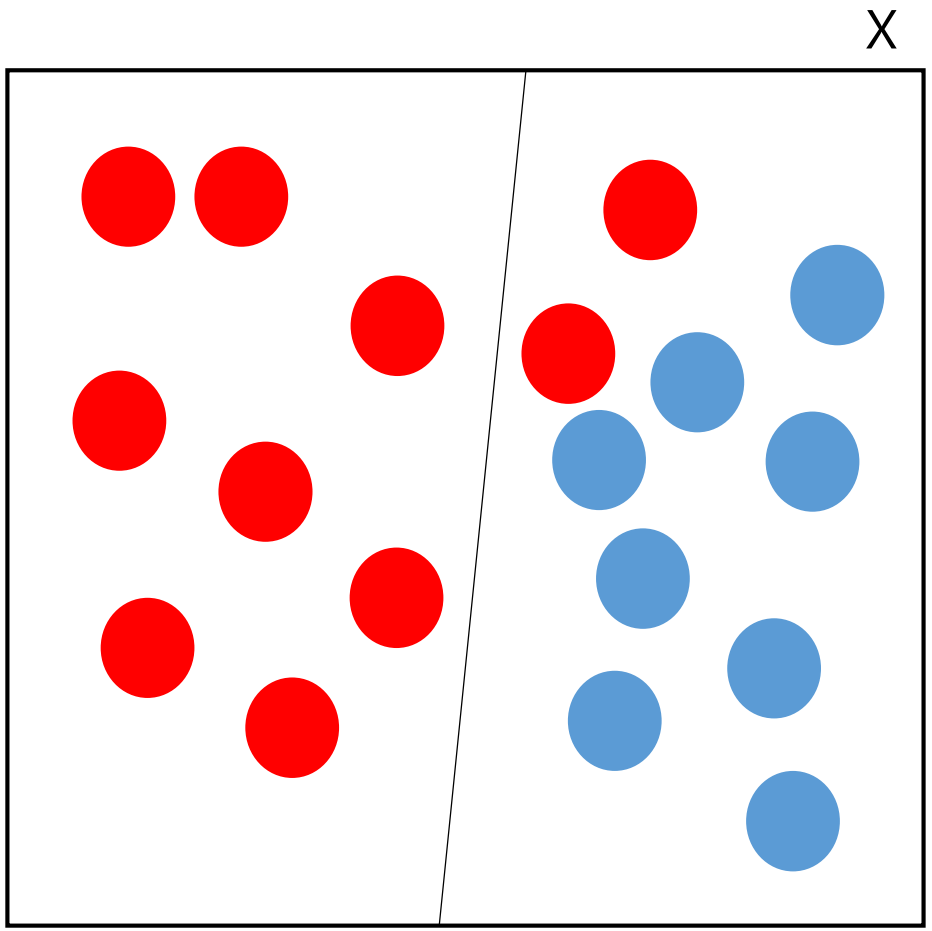

$$Entropy(X) = \sum_{i=1}^{d} R_i \left(-\sum_{j=1}^{n} P_j log_2(P_j)\right)$$

; 이때, R_i는 분할 전 데이터 가운데 분할 후 i범주에 속하는 데이터 비율

$$= \frac{8}{18}(-1 \cdot log_2(1)) + \frac{10}{18}\left(-\frac{2}{10} \cdot log_2\left(\frac{2}{10}\right) - \frac{8}{10} \cdot log_2\left(\frac{8}{10}\right)\right)$$

$$= 0.401$$

0.991 >> 0.401

- 엔트로피 감소
- 불순도 감소
- 잘 분류되었다

엔트로피 (Entropy)

Q1. 분류되기 전의 엔트로피를 구해보세요

$$Entropy(X) = -\sum_{j=1}^{n} P_j log_2(P_j)$$

Q2. 분류된 후의 엔트로피를 구해보세요

$$Entropy(X) = \sum_{i=1}^{d} R_i \left(-\sum_{j=1}^{n} P_j log_2(P_j)\right)$$

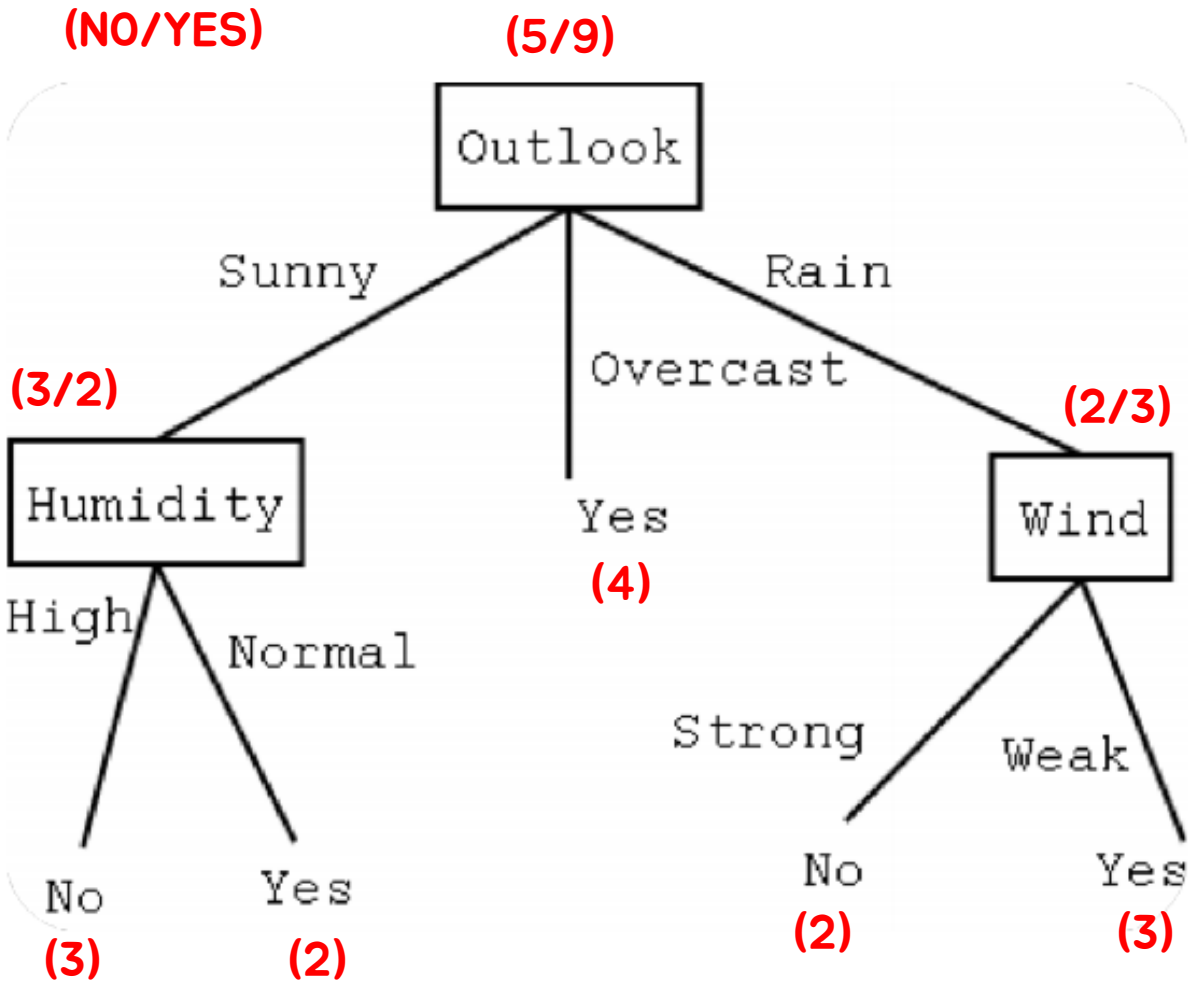

엔트로피 (Entropy)

Q1. 분류되기 전의 엔트로피를 구해보세요

$$= -\frac{5}{14} log_2(\frac{5}{14}) - \frac{9}{14} log_2(\frac{9}{14})$$

= 0.94

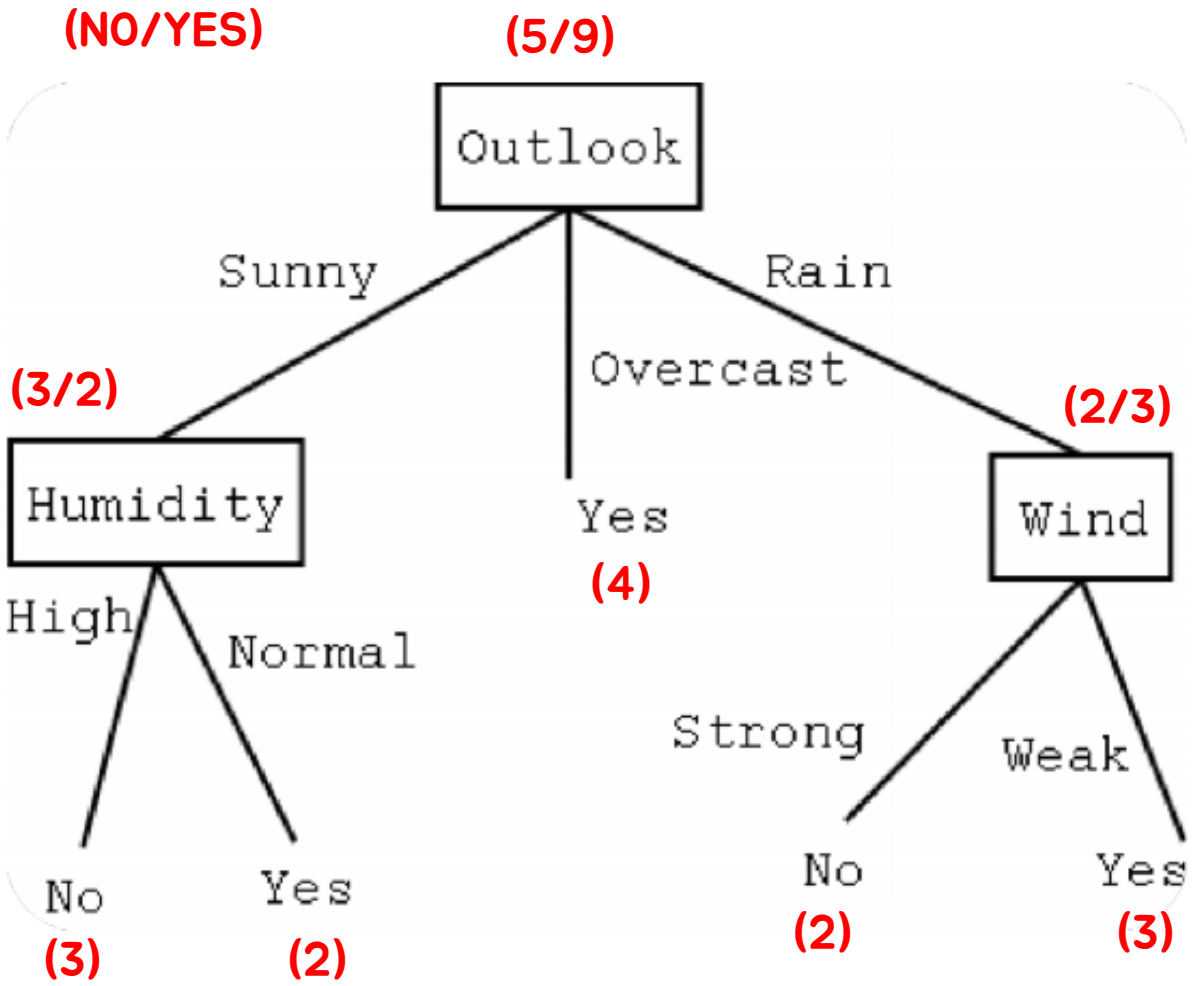

엔트로피 (Entropy)

Q2. 분류된 후의 엔트로피를 구해보세요

$$= \frac{5}{14}\left(-\frac{3}{5}\cdot log_2\left(\frac{3}{5}\right) - \frac{2}{5}\cdot log_2\left(\frac{2}{5}\right)\right)$$
$$+ \frac{4}{14}\left(-\frac{4}{4}\cdot log_2\left(\frac{4}{4}\right)\right)$$
$$+ \frac{5}{14}\left(-\frac{2}{5}\cdot log_2\left(\frac{2}{5}\right) - \frac{3}{5}\cdot log_2\left(\frac{3}{5}\right)\right)$$

= 0.6936

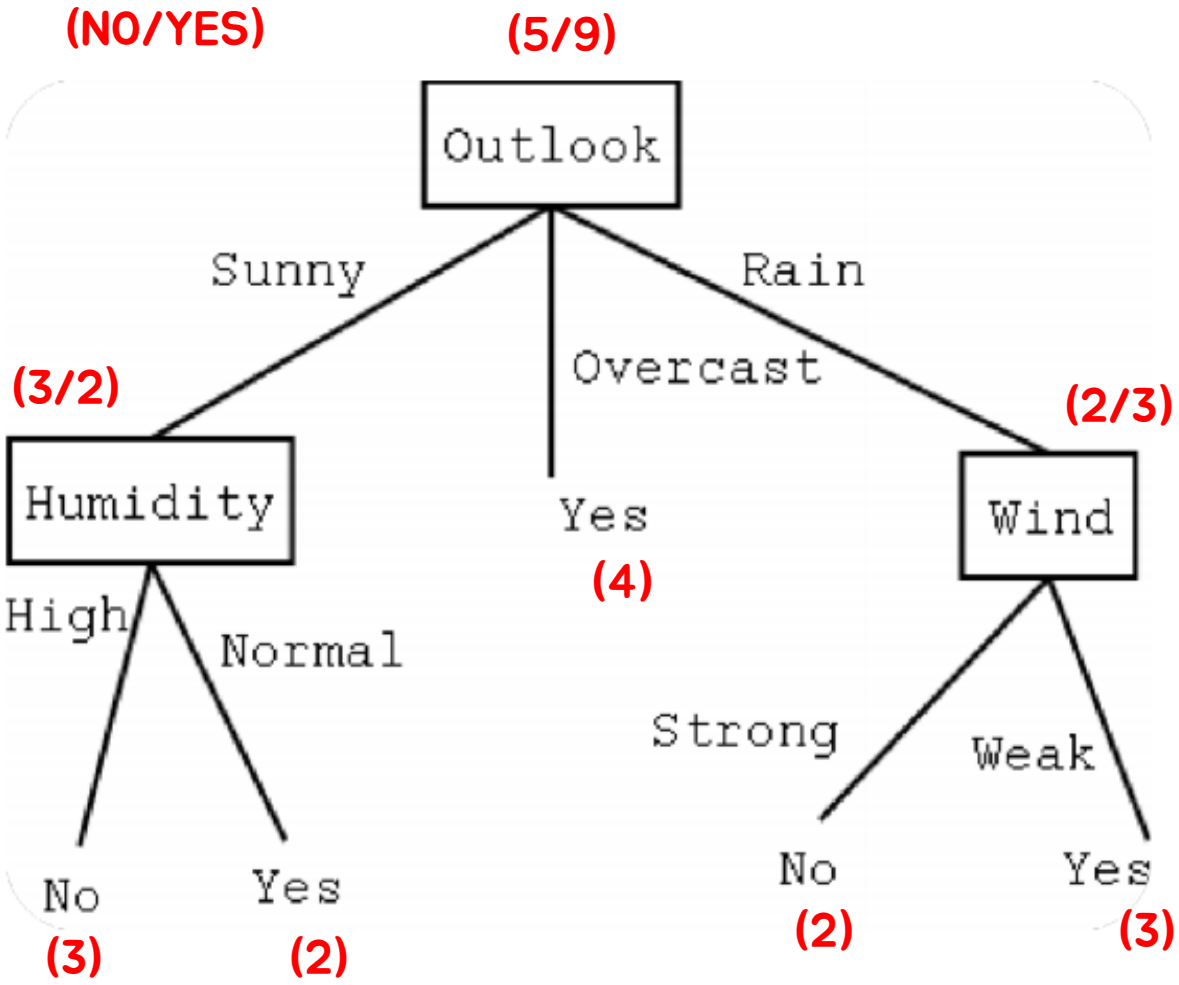

정보획득량 (information gain)

: 어떤 사건이 얼마만큼의 정보를 줄 수 있는지를 수치화한 값
: Entropy(before) - Entropy(after)
: 의사결정트리는 정보획득량을 최대로 하는 순서로 속성을 배치하는 것이 중요
: 각각의 변수들 중 가장 큰 값을 가진 변수를 기준으로 분할을 진행한다.
: 그리고 이러한 과정을 계속 반복하며, gain 값이 어느 정도 0에 가까워지면 계산을 멈춘다.

'그렇다면 정보획득량을 가지고 어떻게 재귀분할 하나요?'

1. 정보획득량이 가장 큰 방향으로 root node를 정한다

Day	Outlook	Temperature	Humidity	Wind	PlayTennis
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

Ex).

$$
\begin{aligned}
Values(Wind) &= Weak, Strong \\
S &= [9+, 5-] \\
S_{Weak} &\leftarrow [6+, 2-] \\
S_{Strong} &\leftarrow [3+, 3-] \\
Gain(S, Wind) &= Entropy(S) - \sum_{v \in \{Weak, Strong\}} \frac{|S_v|}{|S|} Entropy(S_v) \\
&= Entropy(S) - (8/14) Entropy(S_{Weak}) \\
&\quad - (6/14) Entropy(S_{Strong}) \\
&= 0.940 - (8/14)0.811 - (6/14)1.00 \\
&= 0.048
\end{aligned}
$$

$$Gain(S, Outlook) = 0.246$$

$$Gain(S, Humidity) = 0.151$$

$$Gain(S, Wind) = 0.048$$

$$Gain(S, Temperature) = 0.029$$

Outlook이 정보획득량이 가장 커서
Root node로 정함

2. Root node에서 분류된 데이터들의 entropy구하고
그 다음 노드의 attribute를 정보획득량이 큰 기준으로 정한다.

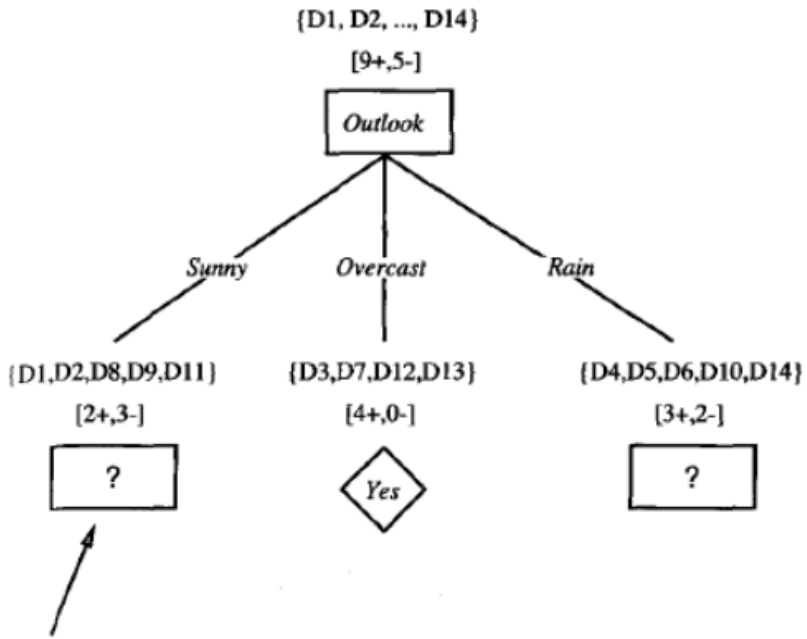

S_{sunny} = {D1,D2,D8,D9,D11}

Gain (S_{sunny}, *Humidity*) = .970 - (3/5) 0.0 - (2/5) 0.0 = .970

Gain (S_{sunny}, *Temperature*) = .970 - (2/5) 0.0 - (2/5) 1.0 - (1/5) 0.0 = .570

Gain (S_{sunny}, *Wind*) = .970 - (2/5) 1.0 - (3/5) .918 = .019

Ex).

S_{sunny} = {D1,D2,D8,D9,D11}

Gain (S_{sunny}, *Humidity*) = .970 - (3/5) 0.0 - (2/5) 0.0 = .970

Gain (S_{sunny}, *Temperature*) = .970 - (2/5) 0.0 - (2/5) 1.0 - (1/5) 0.0 = .570

Gain (S_{sunny}, *Wind*) = .970 - (2/5) 1.0 - (3/5) .918 = .019

Humidity의 정보획득량이 가장 크므로
Sunny의 attribut는 humidity가 온다.

최종 트리

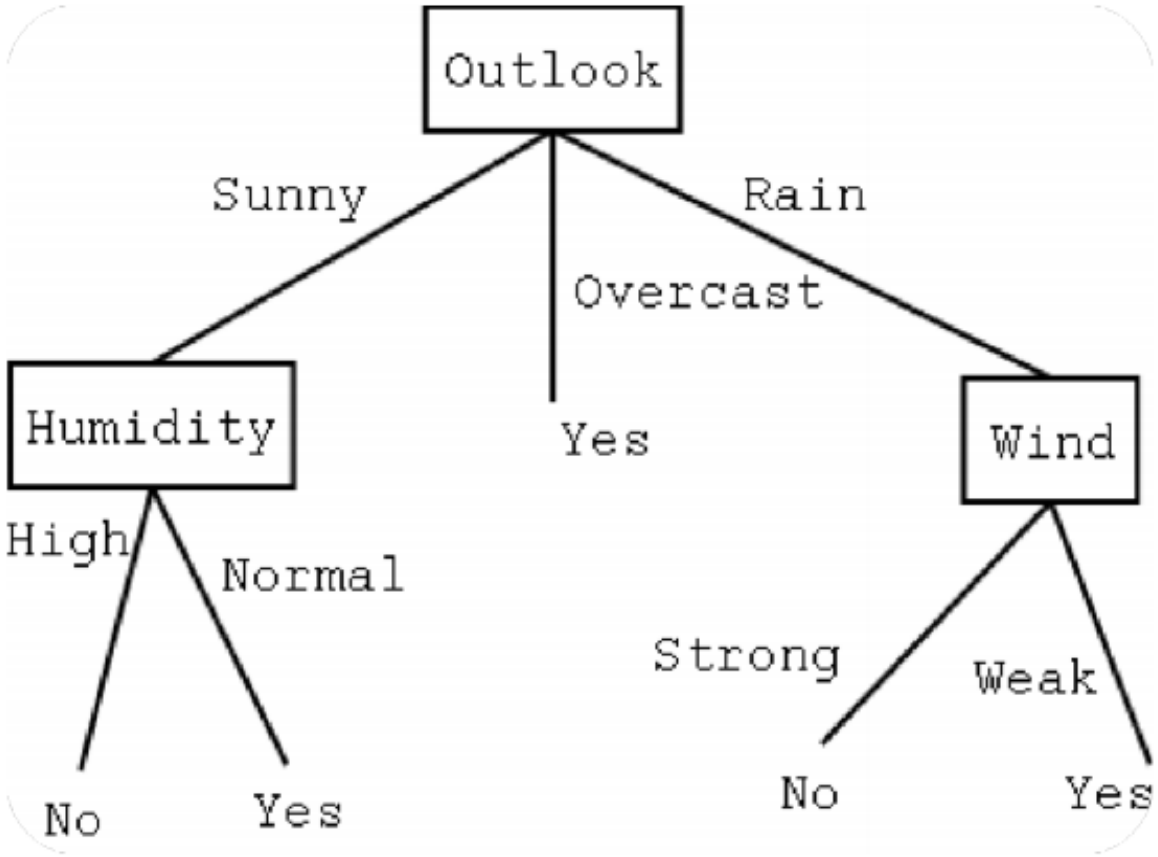

의사결정나무에 중요한 아이디어는 가장 큰 정보획득량을 가지는 attribute를 root에 가깝게 하는 것!

지니지수 (Gini index)

: 불순도를 측정하는 방법 중 하나
: 전체 노드 안에 특정 범주에 속하는 관측치의 비율을 모두 제외한 값

분할전

$$\text{Gini(t)} = 1 - \sum_i [p(i|t)]^2$$

이때, p(i|t) : t노드에 속하는 관측치 가운데 i 번째 범주에 속하는 관측치의 비율

분할후

$$Gini_{split} = \sum_{i=1}^{k} \frac{n_i}{n} Gini(i)$$

이때, 노드 t는 k개의 부분집합으로 나눠지며, ni는 i번째 부분집합의 관측치 개수

지니지수 (Gini index)

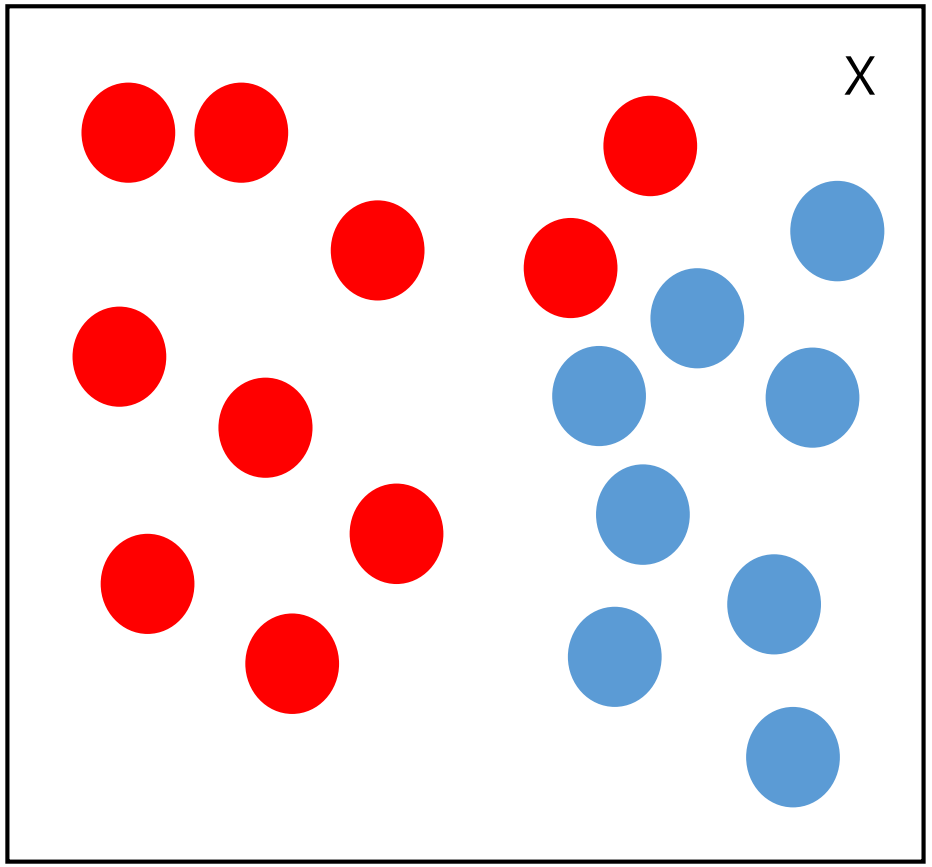

$$Gini(t) = 1 - \sum_i [p(i|t)]^2$$

이때, p(i|t) : t노드에 속하는 관측치 가운데 i 번째 범주에 속하는 관측치의 비율

$$= 1 - (\frac{8}{18})^2 - (\frac{10}{18})^2$$

$$= 0.494$$

Pruning(가지치기)

<Machine Learning>은 사실 이미 output을 알고 있는 데이터에 맞추기 위해서가 아닌 새로운 데이터를 얼마나 잘 예측하는 모델을 세울 수 있을지가 중요하다!!
→ 결국, 단순히 train set의 정확도를 높일 것이 아니라 일반화 성능을 높여야 함!

각종 Splitting Criteria들로 나무를 끝까지 만들 경우overfitting!! (그림의 초록색 선)

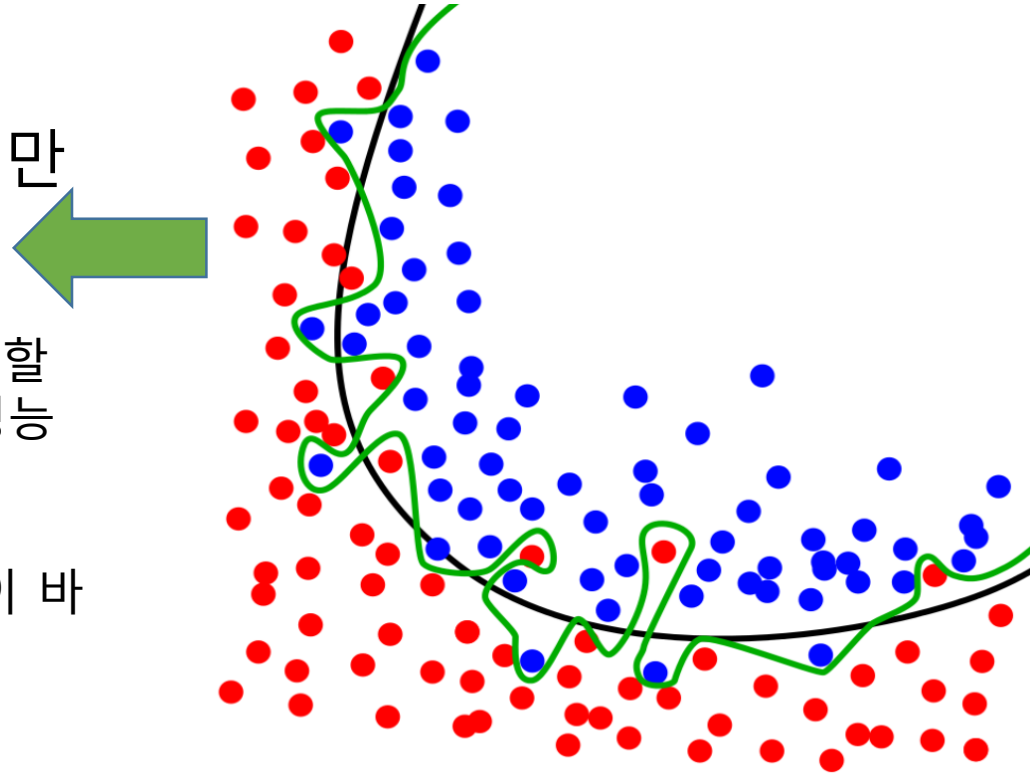

- 이렇게, 초록색 선처럼 모든 데이터 포인트 마다 구분할 경우, outlier들에 영향도 상당히 많이 받고, 일반화 성능이 떨어지는 불안정한 모델이 설계가 될 것!!
- 따라서 사전에 검은색 선처럼 일반화 된 decision boundary를 설정해 주는 것이 좋다. 이를 위한 작업이 바로 "Pruning"이다

Pruning(가지치기)

자! 간단하게 Pruning을 다시 한 번 정리해보자면!!

What is pruning?

- Remove some leaf nodes that could harm future predictions.
- 마지막 leaf nodes들을 좀 제거해서 일반화 성능을 높이려는 것!

Why pruning?

- Escape from overfitting problem
- 모델이 오버피팅되는 문제를 해결하기 위해 진행하는 단계

Pruning(가지치기)

<pre-pruning> 또는 <post – pruning>의 두가지 방법

1. Pre – pruning

말 그대로, 사전에 가지를 치는 것

- max_depth
- min_sample_leaf
- max_leaf_nodes

2. Post – pruning

최대 크기로 키운 후, 가지를 치는 것

- Reduced Error pruning
- Pessimistic error pruning
- Error complexity pruning
- Minimum Error pruning
- Minimal Cost-Complexity Pruning

EX. 과적합 방지를 위한 Pre-Pruning Hyperparameter (rpart)

- maxdepth : Root node에서 Leaf node까지 최장 길이
- minsplit : spliting node에 남아있어야하는 최소한의 records 개수
- minbucket : terminal node에 남아있어야 하는 최소한의 records 개수

그러나 rpart는 pre pruning보다는 post pruning을 하는 것이 일반적!

maxdepth: This parameter is used to set the maximum depth of a tree. Depth is the length of the longest path from a Root node to a Leaf node. Setting this parameter will stop growing the tree when the depth is equal the value set for maxdepth.
minsplit: It is the minimum number of records that must exist in a node for a split to happen or be attempted. For example, we set minimum records in a split to be 5; then, a node can be further split for achieving purity when the number of records in each split node is more than 5.
minbucket: It is the minimum number of records that can be present in a Terminal node. For example, we set the minimum records in a node to 5, meaning that every Terminal/Leaf node should have at least five records. We should also take care of not overfitting the model by specifying this parameter. If it is set to a too-small value, like 1, we may run the risk of overfitting our model.

<Minimal Cost-Complexity Pruning>의 알고리즘

- T : a final tree with leaf nodes
- T_t : a subtree which root node is the node *t*
- $|T|$: complexity of tree T = number of leaf nodes of T
- $|T_t|$: complexity of subtree T_t = number of leaf nodes of T_t
- $R(t)$: misclassification (error) rate of the tree T, when the node *t* is claimed as a leaf node.
- $R(T_t)$: misclassification (error) rate of the subtree T_t itself

- Prune the tree at the node *t* when $\alpha(t)$ is minimal.

$$\alpha(t) = \frac{R(t) - R(T_t)}{|T_t| - 1}$$

<Minimal Cost-Complexity Pruning>의 알고리즘

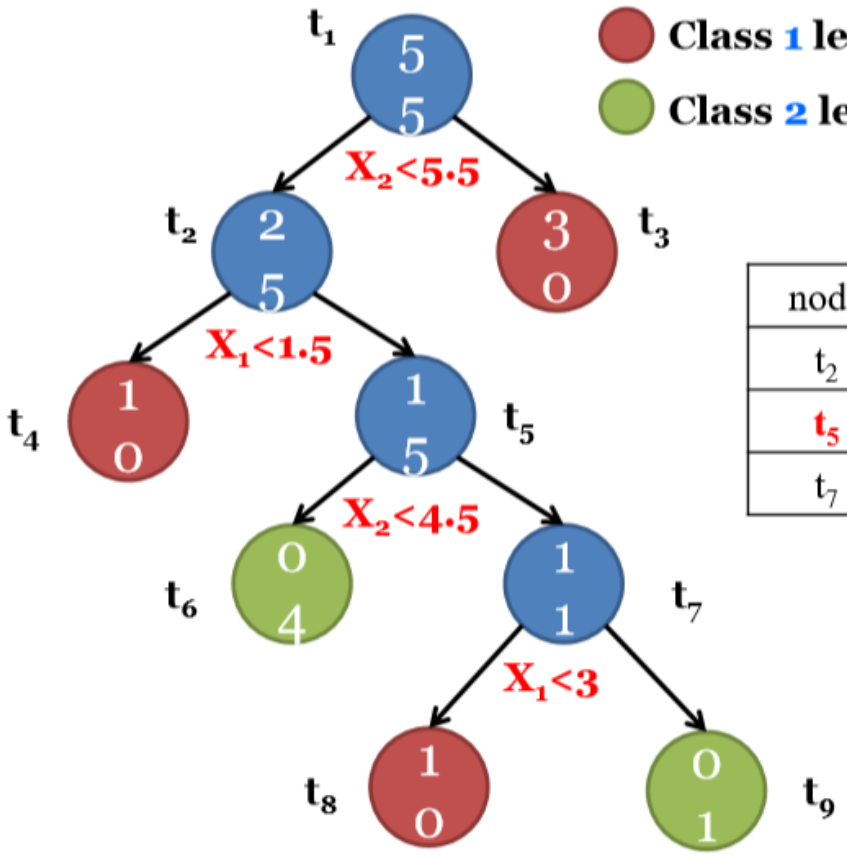

node	$R(t)$	$R(T_t)$	$\lvert T_t \rvert$	$\alpha(t)$
t_2	0.2	0	4	0.067
t_5	0.1	0	3	**0.05**
t_7	0.1	0	2	0.1

같이 계산
해 봅시다,,,
ㅎㅎ

문제 1번.

Question) Consider the CART algorithm to build a decision tree for the data shown below.

X_1	X_2	X_3	Y
0	0	1	B
1	0	1	A
0	1	0	B
1	0	0	B
1	0	1	A
0	0	1	A
1	1	0	B
0	0	0	B
0	1	0	A
1	1	1	A

네. 맞아요. 어려워요.
풀어보세요 ㅎㅎ
같이 풀거에요 ㅎㅎ

(1) Which variable would be chosen as the first splitting variable?
(2) What is the misclassification rate of the best decision tree having two leaf nodes?

3. 과적합 방지를 위한 Post Pruning by CP value

```
> # Pruning (과적합 방지)
> printcp(credit_rpart)

Classification tree:
rpart(formula = default ~ ., data = credit_train)

Variables actually used in tree construction:
[1] age                  amount               checking_balance     credit_history       job
[6] months_loan_duration percent_of_income    phone                savings_balance

Root node error: 210/700 = 0.3

n= 700

        CP nsplit rel error  xerror     xstd
1 0.059524      0   1.00000 1.00000 0.057735
2 0.057143      2   0.88095 0.99048 0.057577
3 0.038095      3   0.82381 0.90000 0.055934
4 0.017460      5   0.74762 0.82857 0.054450
5 0.014286      8   0.69524 0.80000 0.053807
6 0.011905     12   0.62857 0.80476 0.053917
7 0.010000     14   0.60476 0.80476 0.053917
```

```
> plotcp(credit_rpart)
```

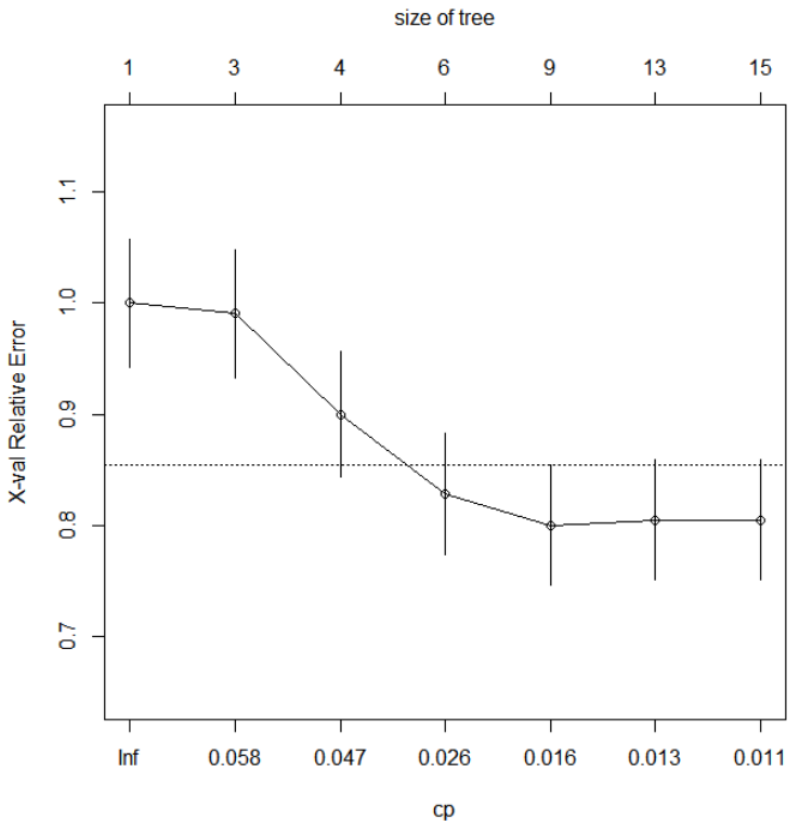

- CP(Complexity Parameter) : 값이 작아질수록 complexity 커짐
- nsplit = 가지의 분기수.(nsplit+1만큼의 leaf node생성)
- rel error=오류율 (1-R^2)
- xerror=교차검증 오류율 (rpart는 built-in cross validatio있음)
- xstd = 교차검증오류의 표준오차.
- Horizontal line : the minimum average cross-validation error + SD of error

3. 과적합 방지를 위한 Post - Pruning

```
# Pruning (과적합 방지)
printcp(credit_rpart)
plotcp(credit_rpart)
credit_prune <- prune(credit_rpart,cp=credit_rpart$cptable[which.min(credit_rpart$cptable[,"xerror"]),"CP"])
plot(credit_prune) ; text(credit_prune)
```

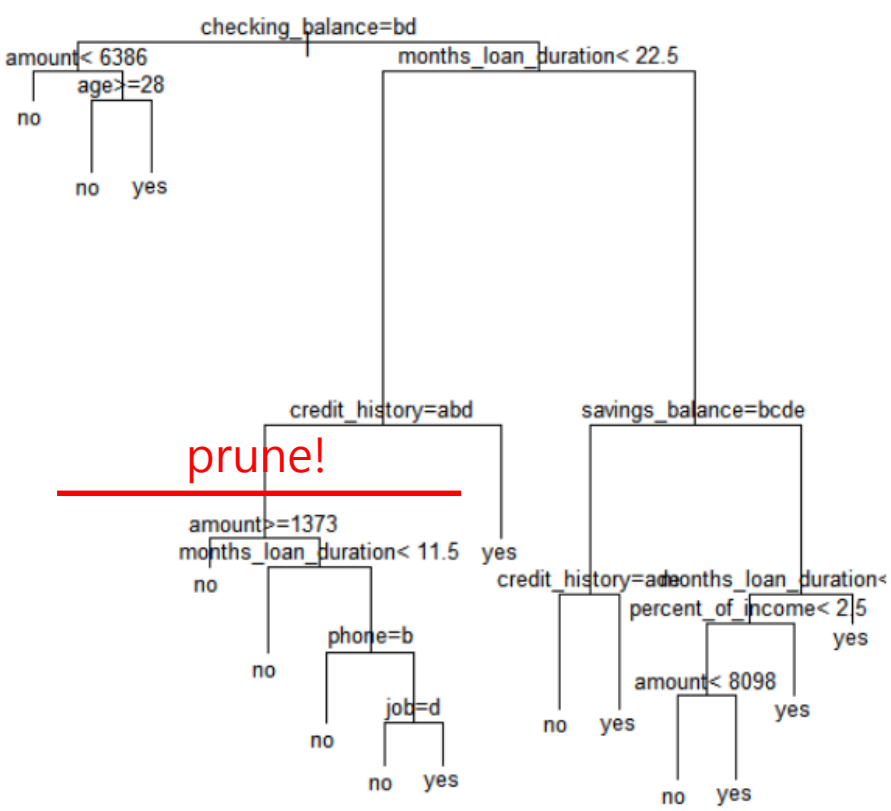

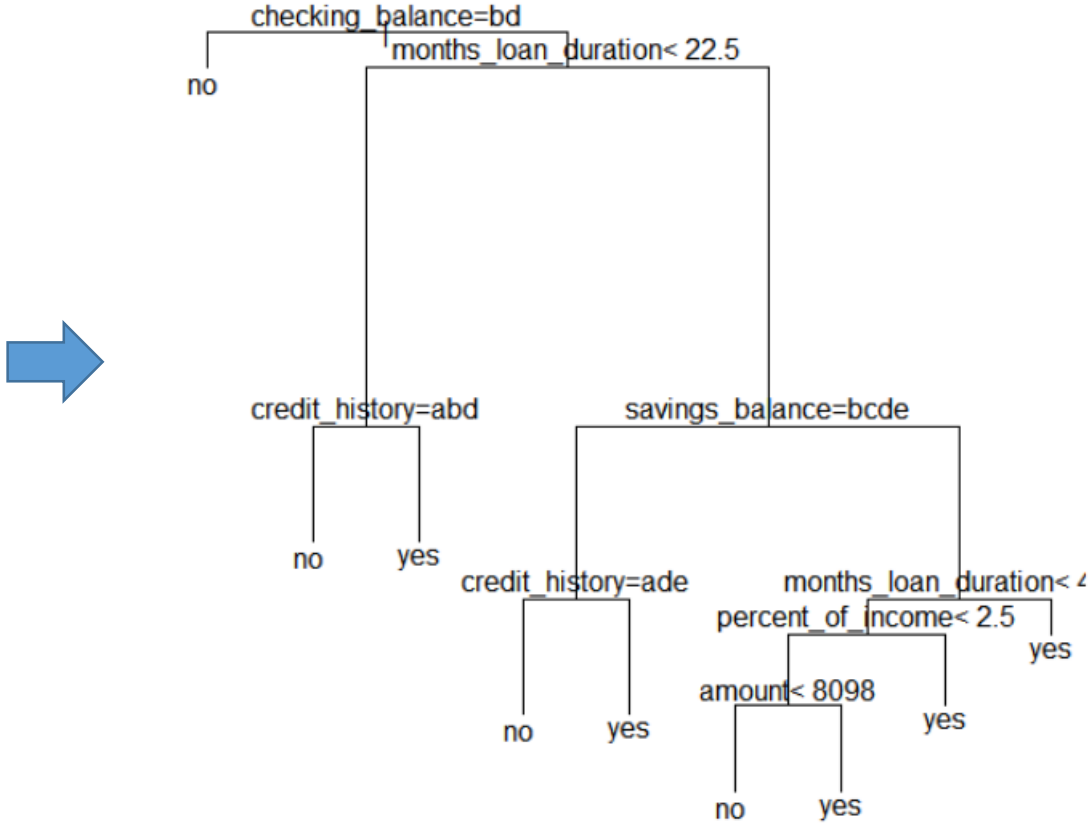

1. 'Classification tree" with C5.0 algorithm

- Decision Tree 알고리즘 중 가장 잘 알려진것 중 하나
- C4.5 알고리즘의 개선 (속도개선, boosting지원)
- Classification만 가능. 엔트로피사용. 다지분리(Multiple split)

강점	약점
• 대부분의 문제에 적합 • NA데이터를 포함한 연속형, 이산형 데이터를 다룰 수 있음 • 중요하지 않은 특징 제거 (pruning) • 훈련 데이터를 구성하는 변수들에 다른 가중치를 적용시킬 수 있음	• Outlier에 취약함.

- C5.0 알고리즘은 '합리적 기본값'을 이용하여 자동적으로 Post-pruning.
- Overfitting 후 Classification error(분류오차)가 작은, 즉 분류에 큰 영향력이 없는 branch제거.
- Subtree Replacement , Subtree Raising
- http://www.bowdoin.edu/~echown/courses/370/tutorial.html : Informal Tutorial

〈 Data설명 〉

- 목적 : C5.0 의사결정 트리를 이용한 간단한 대출승인모델 개발
- 데이터설명 : 독일의 한 신용기관에서 얻은 1000개의 대출예시와 대출 신청자의 특성을 나타내는 수치 특징과 명목 특징을 포함하고 있음.
- 16개의 Predictor variable (수치형,명목형)
  1개의 Response variable(default = 채무불이행여부. Yes/No의 two class)

〈 C5.0 모델링 순서 〉

1. Data split into train and test
   (Prop.table로 y variable 비율확인)
2. Building model
3. Test data에서 Confusion matrix로 성능평가
   (C5.0은 Classification)

4-1. 정확도 향상 by Boosting
4-2. 정확도 향상 by Penalty matrix
5. Test data에서 Confusion matrix로 각 모델 성능평가

1. Data split into train and test set

```
### CREDIT (classification) - C5.0 (Set.seed(3))----------
library(C50)
credit <- read.csv("credit.csv")
str(credit)
summary(credit)

# Dataset split
set.seed(3)
train_sample <- sample(1000,900)
credit_train <- credit[train_sample,]
credit_test <- credit[-train_sample,]

# Train data와 Test data내의 default 비율 비슷한지 확인.
prop.table(table(credit_train$default))
prop.table(table(credit_test$default))
```

```
> str(credit)
'data.frame':   1000 obs. of  17 variables:
 $ checking_balance    : Factor w/ 4 levels "< 0 DM","> 200 DM",..: 1
 $ months_loan_duration: int  6 48 12 42 24 36 24 36 12 30 ...
 $ credit_history      : Factor w/ 5 levels "critical","good",..: 1 2
 $ purpose             : Factor w/ 6 levels "business","car",..: 5 5
 $ amount              : int  1169 5951 2096 7882 4870 9055 2835 6948
 $ savings_balance     : Factor w/ 5 levels "< 100 DM","> 1000 DM",..
 $ employment_duration : Factor w/ 5 levels "< 1 year","> 7 years",..
 $ percent_of_income   : int  4 2 2 2 3 2 3 2 2 4 ...
 $ years_at_residence  : int  4 2 3 4 4 4 4 2 4 2 ...
 $ age                 : int  67 22 49 45 53 35 53 35 61 28 ...
 $ other_credit        : Factor w/ 3 levels "bank","none",..: 2 2 2 2
 $ housing             : Factor w/ 3 levels "other","own",..: 2 2 2 1
 $ existing_loans_count: int  2 1 1 1 2 1 1 1 1 2 ...
 $ job                 : Factor w/ 4 levels "management","skilled",..
 $ dependents          : int  1 1 2 2 2 2 1 1 1 1 ...
 $ phone               : Factor w/ 2 levels "no","yes": 2 1 1 1 1 2 1
 $ default             : Factor w/ 2 levels "no","yes": 1 2 1 1 2 1 1
```

2. Building Model

문법 : C5.0(X variables, Y variable(Categorical), trials= , cost=error cost matrix)

```
## C5.0
# Building model
credit_model <- C5.0(credit_train[-17],credit_train$default)
credit_model #Tree size=69
summary(credit_model) #Error 10.4%
```

Summary 해석

- 수표 계좌잔고(Checking balance) 를 모르거나 200DM이상이고, 다른 신용카드가 없다면 채무불이행 가능성이 없음으로 분류
- 총 346개가 이 조건만족으로 NO라고 분리되었으나 그중 36개의 CASE는 잘못 분류된것.

- 수표계좌잔고가 0보다 작거나, 1~200DM이고, 대출이력이 완벽하거나 아주 좋고, 저금액이 500DM이하이면 채무불이행가능성 있음으로 분류

- 상식적으로 모순된 규칙이 가끔 발견됨 -> 실제 패턴을 반영한 것일 수도, 통계적 이상치 일 수도 있음. 이에 대한 관찰 필요!

```
> summary(credit_model) #Error 10.4%

Call:
C5.0.default(x = credit_train[-17], y = credit_train$default)


C5.0 [Release 2.07 GPL Edition]         Tue Mar 10 14:52:37 2020
-------------------------------

Class specified by attribute `outcome'

Read 900 cases (17 attributes) from undefined.data

Decision tree:

checking_balance in {> 200 DM,unknown}:
:...other_credit = none: no (346/36)
:   other_credit in {bank,store}:
:   :...purpose in {car0,furniture/appliances,renovations}: no (31/4)
:       purpose in {business,car,education}:
:       :...percent_of_income <= 1: no (7/1)
:           percent_of_income > 1:
:           :...existing_loans_count > 2: no (2)
:               existing_loans_count <= 2:
:               :...savings_balance in {< 100 DM,500 - 1000 DM}: yes (17/4)
:                   savings_balance in {> 1000 DM,100 - 500 DM}: no (4/1)
:                   savings_balance = unknown:
:                   :...percent_of_income <= 3: no (4)
:                       percent_of_income > 3: yes (4/1)
checking_balance in {< 0 DM,1 - 200 DM}:
:...credit_history in {perfect,very good}:
    :...savings_balance in {< 100 DM,100 - 500 DM}: yes (54/12)
    :   savings_balance = > 1000 DM: no (1)
    :   savings_balance = 500 - 1000 DM:
    :   :...housing = other: yes (1)
    :   :   housing in {own,rent}: no (3)
    :   savings_balance = unknown:
    :   :...amount <= 4844: yes (2)
    :       amount > 4844: no (3)
    credit_history in {critical,good,poor}:
```

```
Evaluation on training data (900 cases):

  Decision Tree
----------------
Size      Errors

  86   94(10.4%)   <<


 (a)   (b)    <-classified as
----  ----
 599    30    (a): class no
  64   207    (b): class yes


Attribute usage:

100.00% checking_balance
 60.11% other_credit
 53.89% credit_history
 46.78% months_loan_duration
 44.78% savings_balance
 24.00% purpose
 21.44% years_at_residence
 14.33% housing
 14.11% employment_duration
 12.67% job
  9.11% age
  6.67% percent_of_income
  4.00% existing_loans_count
  3.56% amount
  1.67% phone
```

- Tree size
= Number of leaves
- (Train) Error rate
= 10.4%

Variance Importance

3. 기본모델 성능평가 : Test data에서 Confusion Matrix

```
# Confusion matrix
credit_pred <- predict(credit_model,credit_test)
caret::confusionMatrix(credit_pred,credit_test$default)
```

```
> caret::confusionMatrix(credit_pred,credit_test$default)
Confusion Matrix and Statistics

          Reference
Prediction no yes
       no  59  19
       yes 12  10

               Accuracy : 0.69
                 95% CI : (0.5897, 0.7787)
    No Information Rate : 0.71
    P-Value [Acc > NIR] : 0.7127

                  Kappa : 0.1893

 Mcnemar's Test P-Value : 0.2812

            Sensitivity : 0.8310
            Specificity : 0.3448
         Pos Pred Value : 0.7564
         Neg Pred Value : 0.4545
             Prevalence : 0.7100
         Detection Rate : 0.5900
   Detection Prevalence : 0.7800
      Balanced Accuracy : 0.5879

       'Positive' Class : no
```

성능 그닥…
개선 필요해보임

4-1. 정확도 향상을 위한 Adaptive Boosting 모델세우기
앞서 보았듯이 기본 모델의 성능이 그다지 좋지 않으므로 모델을 향상시켜보려한다.

- C4.5에서 C5.0으로 개선된 사항 중 하나인 Adaptive boosting 옵션.
- Adaptive boosting : 여러 개의 의사결정트리(trial)를 만들어 최고 클라스에 투표하게 만드는 과정으로, 맞추기 어려운 문제를 더 잘 맞추게 하는 과정

```
## C5.0 의사결정 트리 정확도 향상
## Adaptive boosting (AdaBoosting)
# Building model
credit_boost10 <- C5.0(credit_train[-17],credit_train$default,trials=10)
credit_boost10 #Tree size = 56.6 (10회의 반복을 통해 트리의 크기가 줄어듬)
summary(credit_boost10) #Error 1.4%
```

```
> credit_boost10 #Tree size = 56.6 (10회의 반복을 통해 트리의 크기가 줄어듬)

Call:
C5.0.default(x = credit_train[-17], y = credit_train$default, trials = 10)

Classification Tree
Number of samples: 900
Number of predictors: 16

Number of boosting iterations: 10
Average tree size: 64

Non-standard options: attempt to group attributes
```

```
Evaluation on training data (900 cases):

Trial        Decision Tree
-----      ----------------
           Size      Errors

   0         86    94(10.4%)
   1         53   176(19.6%)
   2         52   173(19.2%)
   3         67   157(17.4%)
   4         53   177(19.7%)
   5         69   166(18.4%)
   6         64   175(19.4%)
   7         61   173(19.2%)
   8         61   185(20.6%)
   9         74   162(18.0%)
boost              11( 1.2%)


          (a)   (b)    <-classified as
          ----  ----
          627     2    (a): class no
            9   262    (b): class yes
```

(Train)Error rate
10.4%->1.4%

4-2. 정확도 향상을 위한 Penalty 부여 모델 세우기

모델의 정확도를 향상시킬 수 있는 또다른 방법은 Penalty matrix로 manually 조작하는 것.

실제로 채무불이행인데 아니라고 예측한 경우에 대하여 패널티를 더 많이 주자
Why? 은행은 대출을 해주고 반드시 돈을 받아야하는 입장이므로!

```
> ## Penalty 부여
> # Cost matrix
> matrix_dimensions <- list(c("no","yes"),c("no","yes")) #먼저 차원구성
> names(matrix_dimensions) <- c("predicted","actual")
> matrix_dimensions
$predicted
[1] "no"  "yes"

$actual
[1] "no"  "yes"

> error_cost <- matrix(c(0,1,4,0),nrow=2,
+                      dimnames = matrix_dimensions)
> error_cost
         actual
predicted no yes
      no   0   4
      yes  1   0
```

실제로 yes(채무불이행) 인데 예측하기를 no(채무불이행 안함) 으로 한 경우 4의 패널티를, 반대의 경우에는 1의 패널티를 주자

```
# Building model
credit_cost <- C5.0(credit_train[-17],credit_train$default,
                    cost=error_cost)
summary(credit_cost)
```

```
Evaluation on training data (900 cases):

     Decision Tree
   ----------------
   Size      Errors   Cost
     43  194(21.6%)   0.28

    (a)   (b)    <-classified as
   ----  ----
    453   176    (a): class no
     18   253    (b): class yes


Attribute usage:

100.00% checking_balance
 65.44% credit_history
 53.89% months_loan_duration
 48.44% other_credit
 41.11% savings_balance
 36.44% purpose
 24.33% existing_loans_count
 18.56% age
 17.00% job
 10.56% employment_duration
  8.44% amount
  4.33% housing
  4.22% percent_of_income
  4.22% years_at_residence
```

(Train)Error rate
10.4%->1.4%->21.6%
기본 부스팅 패널티

5. 각 모델 성능평가 : Test data에서 Confusion Matrix

```
# Confusion matrix
credit_boost10_pred <- predict(credit_boost10,credit_test)
caret::confusionMatrix(credit_boost10_pred,credit_test$default)
```

```
> caret::confusionMatrix(credit_boost10_pred,credit_test$default)
Confusion Matrix and Statistics

          Reference
Prediction no yes
       no  62  16
       yes  9  13

               Accuracy : 0.75
                 95% CI : (0.6534, 0.8312)
    No Information Rate : 0.71
    P-Value [Acc > NIR] : 0.2222

                  Kappa : 0.3462

 Mcnemar's Test P-Value : 0.2301

            Sensitivity : 0.8732
            Specificity : 0.4483
         Pos Pred Value : 0.7949
         Neg Pred Value : 0.5909
             Prevalence : 0.7100
         Detection Rate : 0.6200
   Detection Prevalence : 0.7800
      Balanced Accuracy : 0.6608

       'Positive' Class : no
```

```
# Confusion matrix
credit_cost_pred <- predict(credit_cost,credit_test)
caret::confusionMatrix(credit_cost_pred,credit_test$default)
```

```
> caret::confusionMatrix(credit_cost_pred,credit_test$default)
Confusion Matrix and Statistics

          Reference
Prediction no yes
       no  41   7
       yes 30  22

               Accuracy : 0.63
                 95% CI : (0.5276, 0.7244)
    No Information Rate : 0.71
    P-Value [Acc > NIR] : 0.9671870

                  Kappa : 0.2722

 Mcnemar's Test P-Value : 0.0002983

            Sensitivity : 0.5775
            Specificity : 0.7586
         Pos Pred Value : 0.8542
         Neg Pred Value : 0.4231
             Prevalence : 0.7100
         Detection Rate : 0.4100
   Detection Prevalence : 0.4800
      Balanced Accuracy : 0.6680

       'Positive' Class : no
```

5. 부스팅 모델 성능평가 : Test data에서 Confusion Matrix (최종)

1) 기본

```
> caret::confusionMatrix(credit_pred,credit_test$default)
Confusion Matrix and Statistics

          Reference
Prediction no yes
       no  59  19
       yes 12  10

               Accuracy : 0.69
```

2) Adaptive Boosting

```
> caret::confusionMatrix(credit_boost10_pred,credit_test$default)
Confusion Matrix and Statistics

          Reference
Prediction no yes
       no  62  16
       yes  9  13

               Accuracy : 0.75
```

3) Penalty Matrix

```
> caret::confusionMatrix(credit_cost_pred,credit_test$default)
Confusion Matrix and Statistics

          Reference
Prediction no yes
       no  41   7
       yes 30  22

               Accuracy : 0.63
```

- Test Accuracy

  0.69 / 0.75 / 0.63
  기본 부스팅 패널티

- 가장 오분류율이 적은 모델 : AdaBoosting 모델
- 그러나 패널티 모델이 은행의 입장에선 가장 좋다. 채무불이행 yes를 no로 분리할 경우 7%로 줄었기 때문!

❖ 부스팅은 보통 좋은 성능을 가지고 오지만,

1) 의사결정 트리를 여러 번 만드는데 드는 시간이 ↑

2) 훈련데이터에 잡음이 많으면 부스팅을 통해 개선이 힘들 수 있음.

따라서 context에 따라 적절한 방법으로 모델성능개선이 필요함

1. "Classification tree" with CART (Classification and Regression tree)

- Response variable : 명목형, 수치형 변수 둘다 가능 <-> C5.0 : 명목형 변수만 가능
- Classification : 지니계수 / Regression : RSS
- Binary split
- Package명: rpart
- 장점 : 연산속도가 빠르다
- 단점 : 과적합화의 위험. 따라서 가지치기 반드시 해야함

< rpart package 모델링 순서 >

1. Data split into train and test
2. Building model
3. Pruning
4. Test data에서 Confusion matrix로 성능평가

1. Data split into train and test set

```
# Dataset split with caret package (Response variable 비율 유지)
library(caret)
set.seed(234)
train_index <- createDataPartition(credit$default, p=0.7)$Resample1
credit_train <- credit[train_index,]
credit_test <- credit[-train_index,]
```

```
> prop.table(table(credit_train$default))

 no yes
0.7 0.3
> prop.table(table(credit_test$default))

 no yes
0.7 0.3
```

2. Building Model

문법 : rpart(Response variable~. , data)

```
# Building model
library(rpart)
credit_rpart <- rpart(default~.,data= credit_train )
plot(credit_rpart) ; text(credit_rpart,cex=0.8)
credit_rpart
```

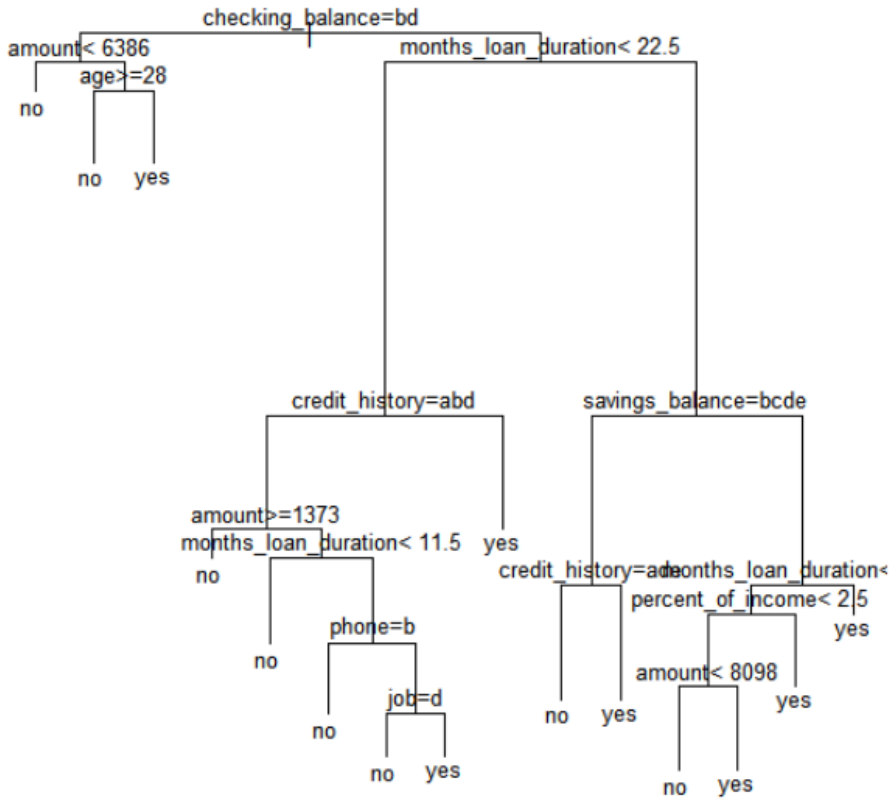

2. Building Model

```
> credit_rpart
n= 700

node), split, n, loss, yval, (yprob)
      * denotes terminal node

  1) root 700 210 no (0.70000000 0.30000000)
    2) checking_balance=> 200 DM,unknown 311  40 no (0.87138264 0.12861736)
      4) amount< 6386 282  29 no (0.89716312 0.10283688) *
      5) amount>=6386 29  11 no (0.62068966 0.37931034)
       10) age>=28 22   5 no (0.77272727 0.22727273) *
       11) age< 28 7   1 yes (0.14285714 0.85714286) *
    3) checking_balance=< 0 DM,1 - 200 DM 389 170 no (0.56298201 0.43701799)
      6) months_loan_duration< 22.5 220  73 no (0.66818182 0.33181818)
       12) credit_history=critical,good,poor 198  58 no (0.70707071 0.29292929)
         24) amount>=1373 113  22 no (0.80530973 0.19469027) *
         25) amount< 1373 85  36 no (0.57647059 0.42352941)
           50) months_loan_duration< 11.5 31   6 no (0.80645161 0.19354839) *
           51) months_loan_duration>=11.5 54  24 yes (0.44444444 0.55555556)
            102) phone=yes 11   3 no (0.72727273 0.27272727) *
            103) phone=no 43  16 yes (0.37209302 0.62790698)
              206) job=unskilled 15   6 no (0.60000000 0.40000000) *
              207) job=skilled,unemployed 28   7 yes (0.25000000 0.75000000) *
       13) credit_history=perfect,very good 22   7 yes (0.31818182 0.68181818) *
      7) months_loan_duration>=22.5 169  72 yes (0.42603550 0.57396450)
       14) savings_balance=> 1000 DM,100 - 500 DM,500 - 1000 DM,unknown 52  20 no (0.61538462 0.38461538)
         28) credit_history=critical,poor,very good 28   4 no (0.85714286 0.14285714) *
         29) credit_history=good,perfect 24   8 yes (0.33333333 0.66666667) *
       15) savings_balance=< 100 DM 117  40 yes (0.34188034 0.65811966)
         30) months_loan_duration< 47.5 94  38 yes (0.40425532 0.59574468)
           60) percent_of_income< 2.5 39  17 no (0.56410256 0.43589744)
            120) amount< 8097.5 27   8 no (0.70370370 0.29629630) *
            121) amount>=8097.5 12   3 yes (0.25000000 0.75000000) *
           61) percent_of_income>=2.5 55  16 yes (0.29090909 0.70909091) *
         31) months_loan_duration>=47.5 23   2 yes (0.08695652 0.91304348) *
```

Regression tree였으면
Node) split, n, deviance, yval

Credit_model 해석

*가 총 15개 이므로 terminal node는 총 15개
Cf) Spliting node에서 해당변수가 NA이면 그대로 terminal node에 떨어진다.

1) Root node : 700건의 total data, 대표그룹=no, no:yes=7:3
2) checking_balance=>200DM,unknown
 : 총 311건의 data, (여기서 끝나면)오분류 40건, 대표그룹=no
4) 그 중 amount<6386
 : 총 282건의 data, 오분류 29건
10) 그 중 age=>28
 : 총 22건, 오분류 5건, 대표그룹=no (Terminal node)

3. 과적합 방지를 위한 Post Pruning by CP value

```
> # Pruning (과적합 방지)
> printcp(credit_rpart)

Classification tree:
rpart(formula = default ~ ., data = credit_train)

Variables actually used in tree construction:
[1] age                  amount               checking_balance     credit_history       job
[6] months_loan_duration percent_of_income    phone                savings_balance

Root node error: 210/700 = 0.3

n= 700

        CP nsplit rel error  xerror     xstd
1 0.059524      0   1.00000 1.00000 0.057735
2 0.057143      2   0.88095 0.99048 0.057577
3 0.038095      3   0.82381 0.90000 0.055934
4 0.017460      5   0.74762 0.82857 0.054450
5 0.014286      8   0.69524 0.80000 0.053807
6 0.011905     12   0.62857 0.80476 0.053917
7 0.010000     14   0.60476 0.80476 0.053917
```

```
> plotcp(credit_rpart)
```

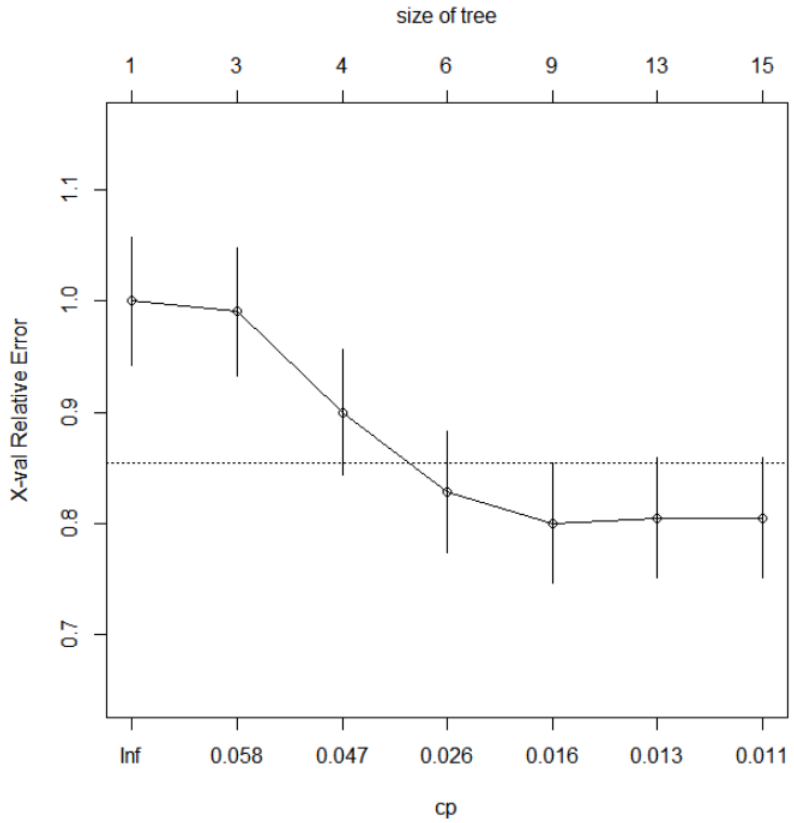

3. 과적합 방지를 위한 Post - Pruning

```
# Pruning (과적합 방지)
printcp(credit_rpart)
plotcp(credit_rpart)
credit_prune <- prune(credit_rpart,cp=credit_rpart$cptable[which.min(credit_rpart$cptable[,"xerror"]),"CP"])
plot(credit_prune) ; text(credit_prune)
```

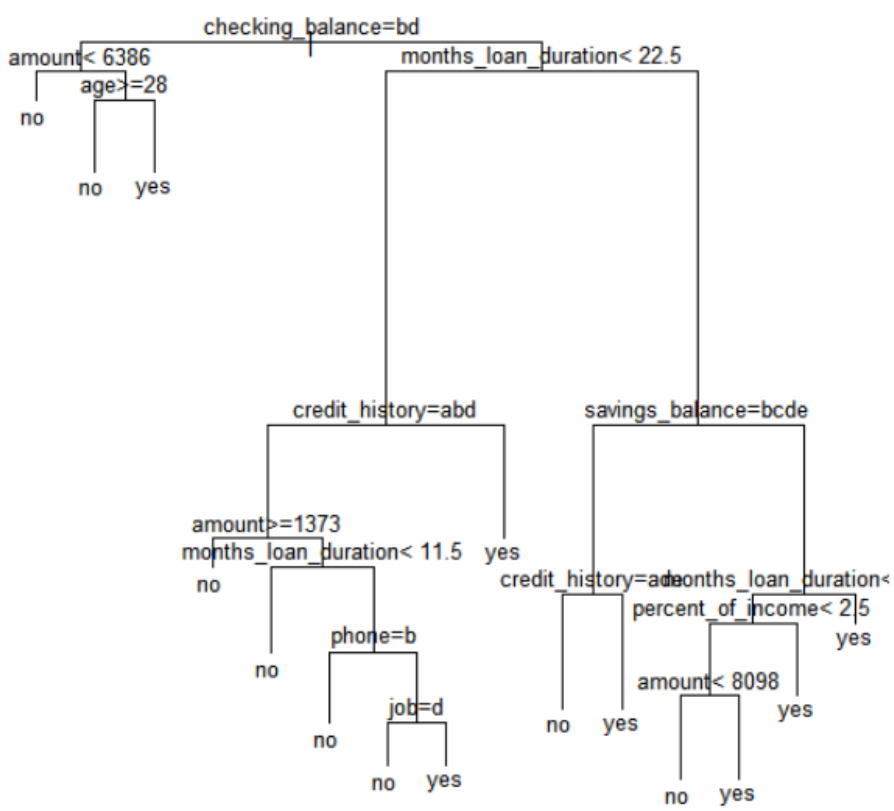

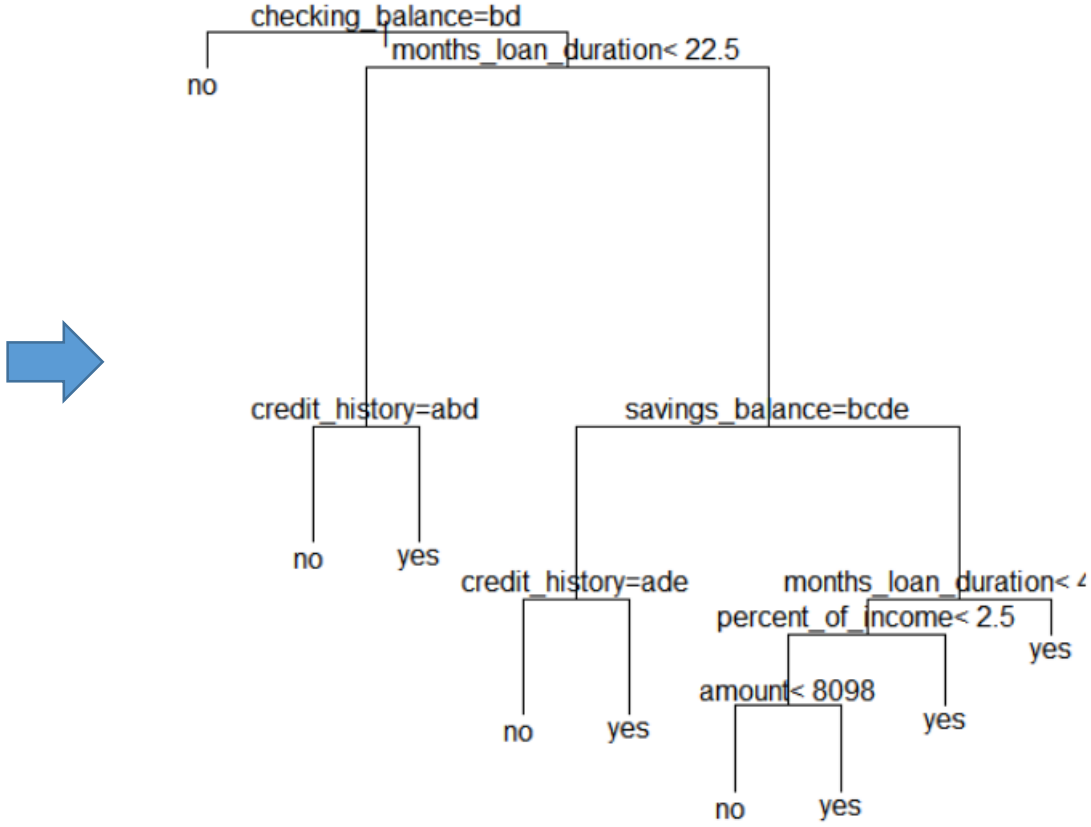

4. Test data에서 Confusion matrix로 각 모델 성능평가

```
> # Test data에서 검정 : Confusion matrix
> credit_pred <- predict(credit_rpart,credit_test,type = "class")
> confusionMatrix(credit_pred, credit_test$default)
Confusion Matrix and Statistics

          Reference
Prediction  no yes
       no  181  53
       yes  29  37

               Accuracy : 0.7267
                 95% CI : (0.6725, 0.7763)
    No Information Rate : 0.7
    P-Value [Acc > NIR] : 0.17257

                  Kappa : 0.2955

 Mcnemar's Test P-Value : 0.01109

            Sensitivity : 0.8619
            Specificity : 0.4111
         Pos Pred Value : 0.7735
         Neg Pred Value : 0.5606
             Prevalence : 0.7000
         Detection Rate : 0.6033
   Detection Prevalence : 0.7800
      Balanced Accuracy : 0.6365

       'Positive' Class : no
```

```
> credit_prune_pred <- predict(credit_prune,credit_test,type = "class")
> confusionMatrix(credit_prune_pred, credit_test$default)
Confusion Matrix and Statistics

          Reference
Prediction  no yes
       no  188  56
       yes  22  34

               Accuracy : 0.74
                 95% CI : (0.6865, 0.7887)
    No Information Rate : 0.7
    P-Value [Acc > NIR] : 0.0722789

                  Kappa : 0.306

 Mcnemar's Test P-Value : 0.0001866

            Sensitivity : 0.8952
            Specificity : 0.3778
         Pos Pred Value : 0.7705
         Neg Pred Value : 0.6071
             Prevalence : 0.7000
         Detection Rate : 0.6267
   Detection Prevalence : 0.8133
      Balanced Accuracy : 0.6365

       'Positive' Class : no
```

http://www.sthda.com/english/articles/35-statistical-machine-learning-essentials/141-cart-model-decision-tree-essentials/

Thank You